AIQUOS 评分机制汇报

各位领导，评分机制我不从原则讲起，咱们直接跟着一个学员走一遍。他叫小林，刚做完二十分钟测评，屏幕上六维雷达图、总分 78 分、B 级。今天就把这个 78 分拆开，看看每一分是怎么来的。

一、小林的二十分钟

小林先和 AI 记者聊了五分钟，聊他自己怎么用 AI；然后做了五分钟选择题，题目难度一路变化；最后五分钟在工作台上真刀真枪指挥 AI 干了个活——把一段口语化的工作汇报改写成正式周报。三个环节各出一个分数，最后合成 78。逐个看。

二、对话采访：评委拿什么打分

小林聊到目标设定时说了两句话。第一句："我让 AI 帮我写周报。"评委判 0.45 档——说清了一件具体的事，但没有任何标准。第二句："我要求不超过四百字、分三段、原始数据一个都不能改。"评委判 0.65 档——有做法、有可检验的标准了。

这就是我们的七档量表，从 0.2 的"只提过"到 1.0 的"能反思 AI 哪里靠不住"，每一档锚定的都是**看得见的行为**，不是"感觉答得不错"。行话这叫行为锚定量表，人事测评用了几十年的方法。评委下判断还有一条铁律：必须摘录小林的原话当证据——他写了"四百字、三段、数据不改"，评委就得把这句贴在评分里，空口无凭不能给高分。

小林五个话题的档位是 0.65、0.45、0.65、0.8、0.65。但只有五条证据，太少了，直接换算容易被一两次发挥带偏。所以证据越少的维度越向基准分收——一条证据只信三分之二，四条基本全信。这叫贝叶斯先验收缩，跟统计里"样本小就别下重注"是一个道理。五条证据算下来，小林对话通道 81 分。

三、客观题：十四道题凭什么测准

传统考试一百道题测的是覆盖面，我们十四道就收卷，凭什么？

因为题目是活的。小林第一题中等难度，对了；系统立刻上调对他的能力估计，第二题变难，又对；再难，错了一道——系统就把他钉在了"中上水平"这个位置附近。这个"每答一题就重新定位、下一题贴着能力出"的做法，行话叫自适应测验，底层是项目反应理论，GRE 和

GMAT 同一套技术。选题的依据叫费雪信息量：题目难度正好卡在你能力边缘时，这道题对你的信息量最大——太简单太难的题都是浪费。

$$P(\text{答对}) = 1 / (1 + e^{(-(\theta - b))})，SE \leqslant 0.42 \text{ 收卷}$$

这条就是核心公式：θ 是小林的能力，b 是题目难度，差距越小越难猜对错。右边那个 SE 是能力估计的不确定度，小林答到第十四题时它降到了 0.42 以下——已经测得够窄了，再多做题是浪费时间，收卷。十四题对十一题，客观通道 72 分。还有一条硬规矩：六个维度任何一个还没采到证据，不许收卷——报告永远是完整的六维，不会缺胳膊少腿。

四、实操：AI 评委怎么看不走眼

小林在工作台写了提示词："你是一名资深行政助理，把下面这段汇报改写成 400 字以内的正式周报，分三段。"生成、看了眼、补了一句"关键数字必须保留"再生成一次。

评委打分看两张量表。提示词这张：角色有（你是资深助理）、约束有（四百字、三段）、边界后来补上了——五个维度过一遍，达标的判"优秀"、基本达标的"良好"、缺项的"待改进"，每个维度配一句具体评语，比如"未说明数据保留范围"。产物那张同理。档位到分数是写死的换算（优秀满分、良好七五折、待改进两五折），评委永远只出档位不出数字——温度漂移、措辞随机就污染不到分数。

评委会不会看走眼？单次判分确实不稳，我们实测重复一致率只有 46.7%，跟抛硬币差不多。解决办法土而有效：同一份作判三次取中位数。中位数的脾气是三票里有一票发疯也不影响结果，行话叫稳健估计。改成三票取中后，十道题十道稳定。小林最后拿了 0.65 的得分率。

还有一个公平问题：小林运气差抽到难题拿 0.65，另一个学员抽到送分题拿 0.8，能说小林更差吗？不能。所以入库前把任务难度加回分数里——难题的 0.65 换算过来的能力值，不低于易题的 0.8。这叫测验等值，跟不同卷子的高考分数对齐是一个原理。

五、78 分是怎么算出来的

小林三条通道的成绩单：客观 72、对话 81、实操 65。能不能 (72+81+65)/3 ≈ 72.7？不能——这三个分数量纲不一样，就像摄氏度的 25 和华氏度的 25 不是一个温度。对话量表天生全员 60 分起步，直接平均等于给对话通道白送十几分。

$$S = 50 + 31.25 \times \text{加权平均}(\theta_{\text{客观}} , \theta_{\text{对话}} , \theta_{\text{实操}})$$

正确做法是先把三个分数都反演回统一的能力尺度 θ，再加权平均，最后线性摊开成百分制。拿小林最强的"提示词工程"维度真算一遍：客观 74 分反演 θ=1.05，对话 88 分 θ=0.8，

实操 0.65 得分率 θ=0.25。权重客观 0.6、对话 0.25、实操 0.15——客观题证据最密拿大头，对话有博弈空间、实操是单次观测，权重都封了顶（跟元分析里"越可靠的信息源话语权越大"一个原则）。算出来 0.87，代入公式 50+31.25×0.87 ≈ 77 分。六个维度各算一遍，平均 78，B 级。每份报告连同三个通道的原始证据一起存档，任何时候都能倒查。

六、牛在哪，虚在哪

牛的地方：技术栈和 GRE 同族；每个分数有原话、有题目、有评语可倒查；三票取中把 AI 评委的不稳定压住了；AI 服务断了还有标注清楚的离线兜底。

虚的地方也直说。公式里的常数——七档锚点、收缩力度、通道权重——都是我们自己的实验标出来的，还没有人类专家基准做背书，教学生、看趋势够用，拿去做选拔认证还不够格；对话评委目前是单票（实操才上了三票）；选择题能蒙对四分之一，公式里没算猜测概率。

所以改进就三件事：找五十份人工双评把锚点钉到人类判断上；对话结束时补一轮三票重判；用真实作答数据重估题目难度。汇报完毕，欢迎提问。